

CLIP (Contrastive Language-Image Pre-training)

1. 개요 및 배경

- 논문명: Learning Transferable Visual Models From Natural Language Supervision (Radford et al., OpenAI, 2021)
- 목표: 인터넷에서 수집한 방대한 '이미지-텍스트 쌍(Image-Text Pairs)'을 활용하여, 별도의 세부 레이블 없이도 다양한 비전 태스크에 곧바로 적용(Zero-Shot Transfer)할 수 있는 범용 비전-언어 모델 학습
- 핵심 개념: 대조 학습(Contrastive Learning)을 통해 이미지와 텍스트를 동일한 다차원 임베딩 공간(Shared Embedding Space)에 매핑하여 서로의 의미를 이해하도록 함

2. CLIP의 핵심 구조 및 작동 원리

CLIP은 크게 이미지 인코더(Image Encoder)와 텍스트 인코더(Text Encoder) 두 개의 모델로 구성됩니다.

구성 요소	역할 및 설명	주요 사용 기술
이미지 인코더 (Image Encoder)	입력된 이미지를 고차원 벡터로 변환	ViT (Vision Transformer) 또는 ResNet
텍스트 인코더 (Text Encoder)	입력된 텍스트(캡션, 설명 등)를 고차원 벡터로 변환	Transformer

- 대조 학습 (Contrastive Pre-training) 방식:

- 배치(Batch) 내에 $N \times N$ 개의 (이미지, 텍스트) 쌍이 주어지면, 모델은 총 $N \times N$ 개의 가능한 조합 중 어떤 이미지와 텍스트가 실제로 짝을 이루는가(Matching)를 예측하도록 학습합니다.
- 진짜 쌍(Diagonal)의 코사인 유사도는 극대화하고, 나머지 가짜 쌍들의 유사도는 최소화하는 대조 손실 함수(Contrastive Loss)를 사용합니다.

3. CLIP의 주요 특징 및 장점

특징 구분	상세 내용
제로샷 전이 (Zero-Shot Transfer)	사전에 학습되지 않은 새로운 이미지 분류 태스크나 도메인에서도, 프롬프트 엔지니어링("A photo of a [class]")만 해주면 추가 학습(Fine-Tuning) 없이 높은 성능을 발휘함
자연어 기반의 유연한 제어	고정된 클래스 레이블(예: 고양이, 개)에 얽매이지 않고, 사용자가 원하는 어떤 문장이든 텍스트 인코더에 넣어 유연하게 분류 및 검색 가능
강건성 (Robustness)	기존 ImageNet 등으로만 학습된 모델에 비해 분포 외(Out-of-Distribution) 데이터나 노이즈에 훨씬 강한 성능을 보임

4. 기존 모델과의 비교

- 기존 컴퓨터 비전 모델: 정해진 카테고리(예: ImageNet 1,000개)의 하드 레이블(Hard Label)에만 의존하여 학습하므로, 새로운 개념을 인식하려면 반드시 추가 데이터 학습이 필요했음
- CLIP: 웹상의 방대한 자연어 감독(Natural Language Supervision)을 활용하여 이미지와 텍스트의 맥락적 관계를 스스로 학습하므로, 훨씬 더 일반화된 시각 지식을 가짐

5. 결론 및 의의

- CLIP은 컴퓨터 비전과 자연어 처리(NLP)를 성공적으로 연결한 획기적인 모델입니다.
- 이미지 검색, 객체 감지뿐만 아니라 DALL-E, Stable Diffusion 등 최신 Diffusion 기반 이미지 생성 모델에서 텍스트 조건을 이미지로 변환해 주는 핵심 브릿지(Conditioning Mechanism)로 광범위하게 활용되고 있습니다.