

Incentivizing Reasoning Capability in LLMs via Reinforcement Learning

0. 결론

이 논문은 (LLM의 추론 능력 향상)을 (사람이 만든 정답 추론 데이터 없이 순수 강화학습만으로) 해결했고, 내게 중요한 포인트는 "정답 검증만 가능하면, 모델이 스스로 사고 과정을 발전시킬 수 있다"는 점이다.

1. 문제 정의 / 동기

- 기존 방법의 한계: 기존 추론 모델들은 사람이 만든 대량의 CoT(단계별 풀이) 데이터로 SFT를 거친 뒤 RLHF를 적용함 → 사람이 만든 추론 데이터를 모으는 비용이 매우 큼
- 이 논문이 겨냥한 상황/가정: "사람이 만든 추론 예시 없이, 정답 검증만 자동으로 가능하면(수학 답, 코드 실행 결과 등) 순수 RL만으로도 추론 능력이 자라날 수 있을까?"

2. 핵심 아이디어 3개

- 아이디어 1: DeepSeek-R1-Zero — SFT 없이 순수 RL만으로 강한 추론 능력을 끌어냄 (단, 가독성 저하·언어 혼용 문제 존재)
- 아이디어 2: DeepSeek-R1 — 소량의 cold-start 데이터로 먼저 워밍업한 뒤 RL을 적용하는 다단계 학습 파이프라인 도입
- 아이디어 3: GRPO(Group Relative Policy Optimization) 알고리즘 사용, 신경망 보상모델 대신 정답 검증(코드 실행, 답 매칭)과 형식 준수를 결합한 규칙 기반 보상으로 보상 해킹 방지

3. 방법(How)

- 모델/알고리즘 흐름: DeepSeek-V3-Base → ① cold-start용 소량 CoT 데이터로 SFT 워밍업 → ② 추론 중심 RL(수학/코드/논리/STEM) → ③ RL 체크포인트에서 rejection sampling으로 SFT 데이터(추론+비추론 약 80만 개) 생성 → ④ 재 SFT + 전체 시나리오 RL(선호 보상 포함)
- Loss/Objective: GRPO 기반 정책 최적화. 보상 = 규칙 기반 정확도/형식 보상(1단계) + 규칙 기반 보상+선호 보상 모델+언어 일관성 보상(2단계)
- 학습/추론 절차: 다단계 파이프라인(cold-start→RL→rejection sampling→SFT→최종 RL). 추론 시 `<think>...</think>` 태그로 사고 과정을, `<answer>...</answer>`로 최종 답을 출력
- 구현 시 주의점: 언어 일관성 보상을 너무 세게 걸면 정확도가 살짝 떨어지는 트레이드오프 존재. GRPO clip ratio가 학습 안정성에 중요한 역할

4. 실험/결과

- 데이터셋/세팅: 수학(AIME 등), 코딩(LiveCodeBench, Codeforces 등), 과학, 논리 추론 벤치마크

- 핵심 수치 2~3개만: R1-Zero의 AIME 2024 정확도가 학습 중 15.6%→77.9%로 급상승. 최종 DeepSeek-R1은 OpenAI-o1-1217과 견줄 만한 추론 성능 달성, Codeforces 상위 96.3% percentile 기록
- ablation에서 "진짜 중요한 것": cold-start 데이터 크기가 작으면(R1-Dev1) 지시 따르기 능력은 늘지만 오히려 AIME 같은 추론 성능은 일부 저하 → cold-start 데이터의 양과 질이 추론력-가독성 트레이드오프를 결정

5. 한계 / 내가 의심하는 점 (Critique)

- 가정이 깨지는 경우: 정답 검증이 가능한 태스크(수학, 코드)에서는 잘 통하지만, 글쓰기 같은 개방형 태스크는 신뢰할 만한 보상모델 구축이 어려워 순수 RL 확장이 제한적
- 재현 난이도: GRPO, 다단계 파이프라인, cold-start 데이터 큐레이션에 상당한 리소스·노하우 필요 (다만 1.5B~70B distilled 모델 6종을 오픈소스로 공개해 접근성은 높임)
- 비교의 공정성: OpenAI-o1과의 비교는 벤치마크 기준이지만, o1의 학습 방식·데이터가 비공개라 완전히 동일한 조건의 비교인지 확인이 어려움