

Improving Language Understanding by Generative Pre-Training (GPT-1)

0. 결론

이 논문은 (자연어 이해 태스크의 라벨 데이터 부족 문제)를 (라벨 없는 텍스트로 언어모델을 사전학습한 뒤 각 태스크에 맞게 **fine-tuning**하는 방법)으로 해결했고, 내게 중요한 포인트는 "모델 구조를 태스크마다 새로 설계하지 않고, 입력 형식만 바꿔서 하나의 사전학습 모델을 재사용할 수 있다"는 점이다.

1. 문제 정의 / 동기 (Why)

- 기존 방법의 한계: 라벨링된 데이터는 태스크마다 부족한데, 라벨 없는 텍스트는 인터넷에 무한히 많음. 기존 **word embedding**(Word2Vec 등) 활용은 단어 수준에만 머물러 있었음
- 이 논문이 겨냥한 상황/가정: 문장/문맥 전체를 이해하는 모델 자체를 사전학습하면, 적은 라벨 데이터로도 다양한 태스크에서 좋은 성능을 낼 수 있을 것이다

2. 핵심 아이디어 3개

- 아이디어 1: 비지도 사전학습(**unsupervised pre-training**) + 지도 **fine-tuning**의 2단계 구조
- 아이디어 2: **Transformer Decoder**(12층)를 언어모델 구조로 채택 — RNN 계열보다 장거리 의존성 학습에 유리
- 아이디어 3: **Traversal-style** 입력 변환 — 구조화된 태스크 입력(문장 쌍, 지문+질문 등)을 특수 토큰으로 이어붙여 하나의 시퀀스로 만들어, 모델 구조 변경 없이 **fine-tuning** 가능하게 함

3. 방법(How)

- 모델/알고리즘 흐름: 라벨 없는 텍스트(**BookCorpus**) → **Transformer Decoder**로 다음 단어 예측 학습 → 사전학습된 모델 → 태스크별 입력을 **traversal-style**로 하나의 시퀀스로 변환 → **fine-tuning**
- **Loss/Objective**: **fine-tuning** 시 "태스크 지도학습 손실 + 언어모델링(다음 단어 예측) 보조 손실"을 함께 사용
- 학습/추론 절차: 사전학습(다음 단어 예측) → **fine-tuning**(태스크 손실+언어모델링 보조손실) → 추론 시 변환된 입력을 넣고 바로 태스크 출력을 냄
- 구현 시 주의점: 언어모델링을 보조 목적함수로 같이 쓰면 (a) 일반화 성능 개선 (b) 수렴 속도 가속 효과가 있음

4. 실험/결과

- 데이터셋/세팅: 문장함의(NLI), 질의응답/상식추론, 문장 유사도, 텍스트 분류 등 12개 태스크
- 핵심 수치 2~3개만: 9/12개 태스크에서 기존 **SOTA**(태스크별 맞춤 설계 모델) 능가. 상식추론(**Stories Cloze Test**) +8.9%p, 질의응답(**RACE**) +5.7%p, 텍스트함의(**MultiNLI**) +1.5%p 개선

- **ablation** : 전이(**transfer**)하는 레이어 수가 많을수록 성능이 좋아짐 → 사전학습된 표현이 실제로 유용한 정보를 담고 있다는 증거

5. 한계 / 내가 의심하는 점

- 가정이 깨지는 경우: 검증 가능한 명확한 정답이 있는 태스크에는 잘 맞지만, 개방형 생성(글쓰기 등)에는 이 프레임워크의 이점이 상대적으로 제한적일 수 있음
- 재현 난이도: 당시 기준으로 대규모 언어모델 사전학습에 상당한 컴퓨팅 자원이 필요했음
- 비교의 공정성: 비교 대상이 각 태스크에 맞춤 설계된(**from-scratch**) 모델들이라, 설계 노력 대비 성능이라는 관점에서는 공정하지만 최고 성능 관점에서는 **100%** 동일선상 비교는 아닐 수 있음