

LoRA (Low-Rank Adaptation)

1. 개요 및 배경

- 논문명: LoRA: Low-Rank Adaptation of Large Language Models (Hu et al., Microsoft, 2021)
- 목표: 수십억~수조 개의 파라미터를 가진 대형 언어 모델(LLM)을 전체 파라미터 재학습(Full Fine-Tuning)하는 대신, 극히 일부의 파라미터만 학습하여 비용과 자원을 획기적으로 절감하는 파인튜닝 기법 제시
- 핵심 개념: 사전 학습된 모델의 가중치 행렬은 고정(Freeze)하고, 가중치 변화량(ΔW)을 저랭크(Low-Rank) 분해 행렬 두 개로 나누어 학습함

2. LoRA의 핵심 원리 및 작동 방식

대형 모델을 파인튜닝할 때 모든 가중치(W)를 업데이트하는 대신, 가중치의 변화량인 ΔW 가 낮은 내재적 차원(Intrinsic Dimension)을 가진다는 점에 착안했습니다.

- 가중치 업데이트 수식:
 - 기존 모델의 출력: $h = W_0 x$
 - LoRA가 적용된 출력: $h = W_0 x + \Delta W x = W_0 x + BA x$
 - W_0 : 사전 학습된 원래의 가중치 행렬 (학습 안 함, Freeze)
 - B 와 A : 새로 추가된 저랭크 행렬 (이 부분만 학습)
- 저랭크 행렬 구조:
 - 원래 행렬의 차원이 $d \times d$ 라면, 이를 $d \times r$ 크기의 행렬 A 와 $r \times d$ 크기의 행렬 B 로 분해 (단, 랭크 $r \ll d$ 로 매우 작음, 예: $r = 4, 8, 16$)

3. LoRA의 주요 특징 및 장점

특징 구분	상세 내용
학습 파라미터 수 급감	전체 파라미터 중 0.01% ~ 1% 미만의 파라미터만 학습하므로 메모리 사용량이 극적으로 감소

추론 지연 시간(Latency) 없음	학습 완료 후, 가중치 행렬 W_0 와 BA 를 하나의 행렬로 합칠 수 있음($W = W_0 + BA$). 따라서 추론 시 추가적인 연산 지연(Overhead)이 전혀 발생하지 않음
스토리지 및 배포 효율성	원래 모델 가중치는 공유하고, 작업별로 아주 작은 크기(수 MB 수준)의 LoRA 모듈 파일만 교체하여 다중 서비스 운영 가능

4. 기존 파인튜닝 방식과의 비교

- **Full Fine-Tuning (전체 미세조정):** 모델의 모든 가중치를 업데이트하므로 엄청난 VRAM과 고성능 GPU 클러스터가 필요하며, 작업마다 거대한 모델 전체를 따로 저장해야 함
- **Adapter / Prefix-Tuning** 등 기존 경량화 기법: 모델 중간에 어댑터 레이어를 끼워 넣는 방식으로 인해 추론 단계에서 지연 시간(Latency)이 발생하는 단점이 있었음
- **LoRA:** 추가 레이어 없이 기존 아키텍처에 병렬 경로만 더하는 방식이라 추론 속도 저하가 없고 성능도 Full Fine-Tuning에 필적함

5. 결론 및 의의

- LoRA는 LLM 커스터마이징의 진입 장벽을 낮춘 혁신적인 기법으로 자리 잡음.
- 개인용 GPU나 제한된 자원 환경에서도 대형 모델을 특정 도메인(의학, 법률, 코딩 등)에 맞게 효율적으로 파인튜닝할 수 있는 표준 방법론이 됨.