

RAG (Retrieval-Augmented Generation)

1. 개요 및 배경

- 논문명: Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks (Lewis et al., 2020)
- 목표: 사전 학습된 대형 언어 모델(LLM)의 고질적인 문제점인 환각(Hallucination) 현상을 완화하고, 외부 지식베이스(Knowledge Base)를 활용하여 최신 정보나 전문 지식을 정확하게 참조할 수 있는 모델 구조 제시
- 핵심 개념: Parametric Memory(모델 내부 파라미터에 저장된 지식)와 Non-Parametric Memory(외부 벡터 DB 등 검색 가능한 문서 집합)를 결합한 하이브리드 접근 방식

2. RAG 모델의 핵심 구조 (Architecture)

RAG는 기본적으로 Retriever(검색기)와 Generator(생성기) 두 가지 컴포넌트로 구성됩니다.

구분	주요 역할 및 설명	주요 사용 기술 / 모델
Retriever (검색기)	입력 쿼리(Query)와 관련된 외부 문서를 대규모 코퍼스에서 효율적으로 탐색 및 추출	DPR (Dense Passage Retrieval), BERT 기반 인코더
Generator (생성기)	검색된 문서(Context)와 원래의 입력 쿼리를 바탕으로 최종 응답 텍스트를 자연스럽게 생성	BART, T5 등 Sequence-to-Sequence 모델

3. RAG의 두 가지 핵심 작동 방식

논문에서는 생성 시 외부 지식을 통합하는 방식에 따라 두 가지 모델을 제안합니다.

1. RAG-Sequence

- 전체 생성 과정 동안 동일한 검색 문서(Top-K)를 고정으로 사용하여 답변을 이어서 생성합니다.

2. RAG-Token

- 토큰을 생성할 때마다 매번 새로운 관련 문서를 검색하여 반영할 수 있으므로, 문맥에 따라 더 유연한 답변 생성이 가능합니다.

4. 기존 모델과의 비교 및 장점

- 기존 **Parametric** 모델(**LLM** 단독)과의 차이:
 1. 모델을 재학습(**Retraining**)하지 않고도 외부 지식베이스만 최신화하면 최신 정보 반영 가능
- 주요 장점:
 1. 환각 현상 감소: 사실 기반의 근거 문서를 바탕으로 답변하므로 정확도 향상
 2. 출처 추적 용이성: 어떤 문서를 참고하여 답변을 생성했는지 확인 가능
 3. 지식 확장성: 학습 데이터에 없는 도메인 지식이나 실시간 정보 활용 가능

5. 결론 및 의의

- RAG는 LLM의 파라미터 한계를 극복하고, 지식 집약적 태스크(**Open-domain QA**, **Fact-checking** 등)에서 **SOTA(State-of-the-Art)** 성능을 달성함.
- 현재 생성형 AI 및 LLM 애플리케이션(**RAG** 챗봇, 사내 문서 검색 시스템 등)의 표준 아키텍처로 자리 잡는 기반이 됨.